

Отчёт о проделанной работе: privacy-preserving обучение флота роботов

Julia Tsvetkova

16 сентября 2026

Содержание

1	Контекст и цель	1
2	Этап 1: аудит новизны исходной заявки	1
3	Этап 2: пивот и 9-месячный роадмап	2
4	Этап 3: матчасть по федеративному обучению флота	2
5	Этап 4: формализация MPC-слоя по итогам созвона	3
6	Статус на конец этапа	4
7	Все использованные источники	4

1 Контекст и цель

Отправная точка — R&D-заявка *Privacy-Preserving Federated Conformal Calibration* (MPC + Rényi DP) для Arenadata: калибровка неопределённости VLA-моделей на edge-роботах через federated conformal prediction с секьюрной агрегацией квантиля non-conformity score. Задача этого этапа работы — (1) оценить реальную новизну заявки, (2) при необходимости перенаправить проект в более сильную научную постановку, (3) построить исполнимый роадмап, (4) заложить математическую матчасть под него, включая доработку MPC-слоя по итогам последнего созвона.

2 Этап 1: аудит новизны исходной заявки

Сверка с литературой ([arXiv:2302.06322] FedCP²-QQ, [arXiv:2306.05131] DP-FedCP, оба 2023) показала: связка federated conformal prediction + differential privacy уже опубликована с 2023 года. Федеративное обучение VLA — тоже закрыто (FedVLA, ICCV 2025). Membership inference на VLA-политиках — закрыто в середине 2026 (две статьи: [arXiv:2605.07088], VLALeaks [arXiv:2606.15165]), причём с разрушительным результатом: temporal-signal атака по действиям робота даёт AUC 0.999, а все проверенные защиты (DP-SGD, шум, округление, MC dropout) либо не работают, либо ломают точность управления.

Вывод: заявленный «research gap» исходной колоды не существует. Открытыми остаются: (C1) реконструкция обучающих данных из политики (не просто обнаружение членства), (C2) систематизация того, почему FL/DP это не останавливают, (C3) защита, снижающая утечку без потери точности управления — именно это прямо названо нерешённой проблемой в VLALeaks.

3 Этап 2: пивот и 9-месячный роадмап

Сформулирован новый проект — *Your Robot Remembers Your Home* — с целевыми venue USENIX Security / IEEE S&P (fallback: CCS, NDSS, NeurIPS D&B, CoRL). Роадмап на 13 недель + фаза масштабирования (мес. 4–9):

Недели	Фаза	Итог
1–2	Воспроизвести и прочесть	OpenVLA-7B + LoRA на LIBERO, $SR \geq 70\%$, one-pager модели угроз
3–6	Воспроизвести атаки	Action-MSE, temporal-curvature, LiRA — таблица AUC, совпадающая с литературой
7–10	Реконструкция и защиты	gradient matching (gray-box) + black-box реконструкция; targeted unlearning + латентный регуляризатор → Парето вне опубликованного фронта
11–13	Абляции и статья	4-стр. workshop-paper подан — временная метка застолблена

Разделение труда: Julia — ML/робототехника (обучение, атаки, защита, эксперименты); научрук из security — формализация модели угроз, методология оценки (TPR@low-FPR, shadow-модели), venue-стратегия.

4 Этап 3: матчасть по федеративному обучению флота

По запросу «проресёрчить федеративное обучение и как это применимо здесь» подготовлено 5 документов (скилл **deep-research**, репозиторий **D:\research-agents**), каждый — обзор области + примеры + тезаурус:

- 01. FL-основы** — FedAvg [McMahan et al., 2017], non-IID-коррекции, связь с проектом (робот = клиент, что едет в облако — веса или скаляр калибровки, не сырые данные).
- 02. Архитектура флота** — три наблюдаемые схемы (fully local / edge-cloud hybrid / fleet-scale пул данных) с примерами (Gemini Robotics On-Device, Tesla FSD, Amazon DeepFleet, Open X-Embodiment/RT-X) и реальной рыночной оценкой Grand View Research: on-premise 73% / cloud 27% выручки рынка ИИ-в-робототехнике (2025) — с честной оговоркой, что это доля выручки, не доля архитектур, и таксономия не совпадает 1:1 с нашей.
- 03. Shamir / MPC** — секьюрная агрегация Bonawitz et al. 2017; установлено, что MPC-слой исходной заявки — не контрибуция, а прямое применение известного протокола; зафиксирован незакрытый gap — byzantine-роботы.

- 04. **Методы агрегации** — FedAvg / secure / робастная (Krum, median) / иерархическая / асинхронная со staleness-взвешиванием; предложена client–edge–cloud топология вместо плоской звезды как более реалистичная для бытовых роботов.
- 05. **Топологии связи** — звезда / иерархическая звезда / decentralized gossip / policy merging; следствие для модели угроз (gray-box vs black-box меняется в зависимости от топологии).

5 Этап 4: формализация MPC-слоя по итогам созвона

По итогам последнего созвона («хорошенько изучить математику процесса и улучшить её») подготовлен документ 06 (06_prss_he_compartmented_threshold.tex), формализующий три пункта из рабочих заметок:

- **PRSS** (Cramer–Damgård–Ishai, TCC 2005, [arXiv через citation graph не индексируется — Springer LNCS 3378]) — механизм, которым N участников генерируют свежие маски для суммирования *без* сервера как участника: структура доступа и PRF-ключи определены только над множеством роботов, сервер не получает ключевого материала ни на каком этапе.
- **Threshold-HE** (threshold Paillier) — альтернатива маскированию: секретный ключ расшифровки сам разделён по Shamir, сервер складывает шифротексты по аддитивному гомоморфизму, расшифровка требует коалиции t участников. Практическое преимущество для роботов с нерегулярным расписанием: синхронизация нужна только на этапе расшифровки, не на каждом раунде маскирования.
- **«Знают двое — знает семья»** — формализовано через compartmented secret sharing (Simmons/Brickell, 1990): введён *домохозяйственный след* $h(S)$ — число независимых домохозяйств в скомпрометированном множестве S , а не сырое число роботов $|S|$, как корректная единица измерения силы коалиции.

Направление улучшения (arXiv MCP, 2023–2025)

Целевой поиск через deep-research/arXiv MCP дал более сильную и современную альтернативу compartmented-схеме 1990 года:

- **Verifiable Weighted Secret Sharing** [arXiv:2505.24289, 2025] — вес $\omega_i = 1/|H_{j(i)}|$ на робота делает правило «знают двое — знает семья» прямым следствием весовой формулы, а не отдельной надстройкой; плюс верифицируемость против злонамеренного дилера и $100\times$ выигрыш по коммуникации против наивной взвешенной VSS.
- **FedGT** [arXiv:2305.05506, 2023] — group testing поверх той же группировки по домохозяйствам закрывает byzantine-gap, отмеченный в документе 03, тем же организационным примитивом, без отдельного механизма.
- **Optimal Computational Secret Sharing** [arXiv:2502.02774, 2025] — граница эффективности по размеру доли $\frac{|S|+|K|}{t}$ как ориентир для реализации на ограниченном бортовом хранилище робота.

Предложенное совмещение этих трёх компонентов специально под флот роботов, сгруппированных по домохозяйствам, в проверенной литературе не найдено — это кандидат на самостоятельный вклад уровня C2/C3 внутри основного security-роадмапа, не просто инженерная деталь.

6 Статус на конец этапа

Документ	Статус
Artifact-роадмап (HTML)	Опубликован, 9-месячный план по неделям
01 – FL-основы	Готово, 0 ошибок компиляции
02 – Архитектура флота	Готово, с примерами и рыночной оценкой
03 – Shamir/MPC	Готово, byzantine-gap зафиксирован
04 – Методы агрегации	Готово
05 – Топологии связи	Готово
06 – PRSS/HE/compartimented + улучшение	Готово, 6 стр., включает предложение на базе arXiv 2023–2025

Дальше по плану: недели 1–2 основного роадмапа (инфраструктура OpenVLA + LIBERO, чтение) остаются следующим шагом; предложенная weighted-verifiable конструкция из раздела 4 — кандидат на отдельную проверку внутри фазы 2 (недели 9–10, defense-эксперименты) до того, как она попадёт в финальный текст статьи.

7 Все использованные источники

Полный список, по этапам работы; источники, повторяющиеся в нескольких документах-матчасти, приведены один раз.

Этап 1 — аудит исходной заявки

- Humbert et al. *One-Shot Federated Conformal Prediction (FedCP²-QQ)*. ICML 2023. <https://arxiv.org/abs/2302.06322>
- Plassier et al. *Conformal Prediction for Federated Uncertainty Quantification Under Label Shift (DP-FedCP)*. ICML 2023. <https://arxiv.org/abs/2306.05131>
- *FedVLA: Federated Vision-Language-Action Learning*. ICCV 2025. <https://arxiv.org/abs/2508.02190>
- *ForgeVLA*. <https://arxiv.org/abs/2605.07474>
- *Membership Inference Attacks on Vision-Language-Action Models*. <https://arxiv.org/abs/2605.07088>
- *VLALeaks*. <https://arxiv.org/html/2606.15165v1>
- Carlini et al. *Extracting Training Data from Large Language Models*. USENIX Security 2021. <https://www.usenix.org/system/files/sec21-carlini-extracting.pdf>
- *SoK: Security and Privacy of Foundation-Model-Powered Robots*. <https://arxiv.org/pdf/2606.16788>

- *Privacy Risks in Reinforcement Learning for Household Robots*. <https://arxiv.org/abs/2306.09273>
- *Fine-Tuning Vision-Language-Action Models (OpenVLA-OFT)*. <https://arxiv.org/abs/2502.19645>

Этап 3 — матчасть по FL (документы 01–05)

01 — FL-основы

- McMahan et al. *Communication-Efficient Learning of Deep Networks from Decentralized Data (FedAvg)*. AISTATS 2017. <https://arxiv.org/abs/1602.05629>
- *Momentum Benefits Non-IID Federated Learning*. <https://arxiv.org/abs/2306.16504>
- *FedDRL*. <https://arxiv.org/abs/2208.02442>
- *Client Adaptation improves FL with Simulated Non-IID Clients*. <https://arxiv.org/abs/2007.04806>
- *Federated Learning Survey: Multi-Level Taxonomy of Aggregation Techniques*. <https://arxiv.org/abs/2511.22616>

02 — Архитектура флота

- *Learning While Deploying: Fleet-Scale RL for Generalist Robot Policies*. <https://arxiv.org/abs/2605.00416>
- *Advancing Multi-Robot Networks via MLLM-Driven Sensing, Communication, and Computation*. <https://arxiv.org/pdf/2604.00061>
- *Offload or Overload*. <https://arxiv.org/html/2603.18284>
- *RAPID: Edge-Cloud Partitioned Inference for VLA*. <https://arxiv.org/pdf/2603.07949>
- *Robot Fleet Learning via Policy Merging (FLEET-MERGE)*. <https://arxiv.org/abs/2310.01362>
- *Open X-Embodiment: Robotic Learning Datasets and RT-X Models*. <https://arxiv.org/abs/2310.08864>
- Google DeepMind. *Gemini Robotics On-Device*. deepmind.google (блог).
- *Offline Edge AI Robotics: Air-Gapped Suitcase Robot on Jetson Orin NX*. <https://dasroot.net/posts/2026/05/offline-edge-ai-robotics-jetson-orin-nx-gemma-4-air-gapped/>
- *Boosting Productivity with Industrial Robots*. <https://www.automate.org/news/industrial-robots-remo>
- *Computer Vision at Tesla for Self-Driving Cars*. thinkautonomous.ai.
- *How Amazon deploys robots in its operations facilities*. <https://www.aboutamazon.com/news/operations/how-amazon-deploys-robots-in-its-operations-facilities>
- Grand View Research. *Artificial Intelligence In Robotics Market Report*. <https://www.grandviewresearch.com/industry-analysis/artificial-intelligence-ai-robotics-market-report>

03 — Shamir/MPC

- A. Shamir. *How to Share a Secret*. CACM 22(11), 1979.
- Bonawitz et al. *Practical Secure Aggregation for Privacy-Preserving Machine Learning*. ACM CCS 2017. <https://dl.acm.org/doi/10.1145/3133956.3133982>
- *PQSF: Post-Quantum Secure Privacy-Preserving FL*. Scientific Reports, 2024.
- *Group Verifiable Secure Aggregate FL Based on Secret Sharing*. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11926380/>
- *SoK: Secure Aggregation based on Cryptographic Schemes for FL*. EURECOM. <https://www.eurecom.fr/publication/6974/download/comsys-publi-6974.pdf>
- *SABLE: Secure And Byzantine robust LEarning*. <https://arxiv.org/abs/2309.05395>

04 — Методы агрегации

- *Asynchronous Hierarchical Federated Learning*. <https://arxiv.org/abs/2206.00054>
- *Timely Asynchronous Hierarchical FL: Age of Convergence*. <https://arxiv.org/abs/2306.12400>
- *Asynchronous FL on Heterogeneous Devices: A Survey*. <https://arxiv.org/abs/2109.04269>
- *Asynchronous Multi-Server FL for Geo-Distributed Clients*. <https://arxiv.org/pdf/2406.01439>

05 — Топологии связи

- *Topology-aware Federated Learning in Edge Computing: A Comprehensive Survey*. <https://arxiv.org/abs/2302.02573>
- *Decentralized Federated Learning: A Survey and Perspective*. <https://arxiv.org/abs/2306.01603>
- *Decentralized Federated Averaging via Random Walk*. <https://arxiv.org/abs/2508.21286>
- *Graph-based Gossiping for Communication Efficiency in Decentralized FL*. <https://arxiv.org/abs/2506.10607>
- *Privacy-preserving Decentralized FL over Time-varying Communication Graph*. <https://arxiv.org/abs/2210.00325>
- *Secure Decentralized FL via Gossip and Virtual Voting*. <https://arxiv.org/abs/2607.08651>

Этап 4 — формализация MPC (документ 06)

- Cramer, Damgård, Ishai. *Share Conversion, Pseudorandom Secret-Sharing and Applications to Secure Computation (PRSS)*. TCC 2005. https://link.springer.com/chapter/10.1007/978-3-540-30576-7_19
- *Generalized Pseudorandom Secret Sharing and Efficient Straggler-Resilient Secure Computation*. Springer, 2021.

- P. Paillier. *Public-Key Cryptosystems Based on Composite Degree Residuosity Classes*. EUROCRYPT 1999.
- G. Simmons. *How to (Really) Share a Secret*. CRYPTO 1990; E. Brickell. *Some Ideal Secret Sharing Schemes*. EUROCRYPT 1989/90.
- Shehata, Han, Thyagarajan. *Verifiable Weighted Secret Sharing*. 2025. <https://arxiv.org/abs/2505.24289>
- Xhemrishi et al. *FedGT: Identification of Malicious Clients in FL with Secure Aggregation*. 2023. <https://arxiv.org/abs/2305.05506>
- Aureliano, Cohen, D'Oliveira. *Optimal Computational Secret Sharing*. 2025. <https://arxiv.org/abs/2502.02774>