

Федеративное обучение: основы и применение к парку роботов

11 сентября 2026

1 Определение

Федеративное обучение (FL, *federated learning*) — парадигма обучения, в которой модель обучается на данных, распределённых по множеству устройств (клиентов), без централизованного сбора самих данных. Термин и первый практический алгоритм ввели McMahan с соавторами в работе *Communication-Efficient Learning of Deep Networks from Decentralized Data* [1], где сформулированы три определяющих свойства задачи: клиентские данные **non-IID** (распределены неоднородно между клиентами), клиентов **много** (массовая распределённость), и на каждом раунде обучения доступна лишь **часть** клиентов (частичное участие).

2 Алгоритм FedAvg

Обучение организовано раундами. На раунде t :

1. Сервер рассылает текущие веса w_t подвыборке клиентов.
2. Каждый клиент k выполняет несколько шагов SGD на своих локальных данных, получая w_t^k .
3. Клиент отправляет серверу обновление — веса w_t^k или дельту $\Delta_k = w_t^k - w_t$. **Сырые данные клиента никогда не покидают устройство.**
4. Сервер агрегирует взвешенным средним по объёму локальных данных n_k :

$$w_{t+1} = \sum_k \frac{n_k}{n} w_t^k, \quad n = \sum_k n_k.$$

Важно: сокрытие сырых данных — необходимое, но *не достаточное* условие приватности. По пересылаемым обновлениям Δ_k можно частично реконструировать исходные данные (gradient inversion) — это мотивирует дополнительные слои защиты (дифференциальная приватность, secure aggregation), рассмотренные в отдельных разделах этого ресёрча.

3 Проблема non-IID и способы её смягчения

Ванильный FedAvg деградирует при сильной неоднородности клиентских распределений. Основные направления коррекции:

- момент-based коррекция локального SGD [2];
- адаптивная агрегация через обучение с подкреплением [3];

- клиентская адаптация модели к локальному сдвигу распределения [4].

Общее ограничение этого семейства: каждый приём требует пересылки дополнительной статистики о клиентском распределении, что расширяет поверхность потенциальной утечки — прямое противоречие с целью приватности проекта.

Свежая работа [5] даёт единую таксономию: топология (централизованная / децентрализованная / иерархическая) и режим агрегации (синхронный / асинхронный) — она используется как индекс в остальных разделах этого ресёрча (архитектура флота, MPC, методы агрегации, топологии связи).

4 Применение к парку VLA-роботов

Каждый робот выступает клиентом FL. Локально он либо (а) дообучает VLA-политику на своих демонстрациях, либо (б) считает локальную статистику калибровки (non-conformity score для conformal prediction). В обоих случаях данные дома — планировка, объекты, присутствие людей — никогда явно не покидают робота; покидают только веса/дельты модели или скалярные статистики. Ключевая сложность именно этого сценария — сильный non-IID между домами (кухня vs спальня, разные бытовые привычки), что делает выбор между ванильным FedAvg и non-IID-коррекцией практически, а не теоретическим вопросом: коррекция даёт лучшую sample efficiency ценой пересылки дополнительной статистики, которую нужно защищать отдельно.

5 Соседние области

Distributed SGD / parameter server — исторический предшественник FedAvg, перенос почти прямой; отличие FL — non-IID и partial participation как первоклассные ограничения. *Split learning* — альтернатива для случаев, где даже обновления модели слишком чувствительны: модель физически разрезается между устройством и сервером. Перенос дорогой (redesign архитектуры VLA), и разрезание добавляет задержку в контур управления — риск для латентности реального времени.

6 Тезаурус

Федеративное обучение (FL) Обучение модели на данных, распределённых по множеству устройств, без централизованного сбора самих данных — на сервер едут только обновления модели.

Клиент Устройство (в этом проекте — робот), локально обучающееся на своих данных и отправляющее обновления координатору.

Раунд Один цикл: рассылка весов → локальное дообучение → отправка обновлений → агрегация на сервере.

FedAvg Базовый алгоритм FL: сервер усредняет клиентские веса, взвешивая по объёму локальных данных n_k каждого клиента.

Non-IID Свойство клиентских данных быть неоднородно распределёнными между устройствами (например, разные комнаты дают разные распределения наблюдений) — основная причина деградации ванильного FedAvg.

Partial participation Не все клиенты доступны на каждом раунде обучения — сервер работает с подвыборкой.

Gradient inversion Атака, восстанавливающая исходные данные клиента по пересылаемому обновлению (градиенту/дельте весов) — причина, по которой сокрытия сырых данных недостаточно для приватности.

Дифференциальная приватность (DP) Формальная гарантия, ограничивающая, сколько информации об отдельном примере можно извлечь из выхода алгоритма (добавлением контролируемого шума).

Split learning Альтернатива FL, при которой сама модель физически разрезается между устройством и сервером, а не переобучается целиком на каждом клиенте.

Список литературы

- [1] B. McMahan, E. Moore, D. Ramage, S. Hampson, B. Agüera y Arcas. *Communication-Efficient Learning of Deep Networks from Decentralized Data*. AISTATS, 2017.
- [2] *Momentum Benefits Non-IID Federated Learning Simply and Provably*. arXiv:2306.16504, 2023.
- [3] *FedDRL: Deep Reinforcement Learning-based Adaptive Aggregation for Non-IID Data in Federated Learning*. arXiv:2208.02442, 2022.
- [4] *Client Adaptation improves Federated Learning with Simulated Non-IID Clients*. arXiv:2007.04806, 2020.
- [5] *Federated Learning Survey: A Multi-Level Taxonomy of Aggregation Techniques, Experimental Insights, and Future Frontiers*. arXiv:2511.22616, 2025.