

Где находится «мозг» робота: архитектура флота

11 сентября 2026

1 Постановка вопроса

При обучении группы роботов не существует единственно верного ответа «мозг вынесен» или «мозг в машине» — на практике используется гибридная схема, и то, как именно она устроена, определяет threat model: кто видит обновления модели, кто видит только действия робота.

2 Три наблюдаемые архитектуры

Архитектура	Inference	Обучение	Синхронность между роботами
Fully local	на роботе	на роботе (редко)	нет: каждый автономен, знания не расходятся
Edge-cloud hybrid	на роботе (латентность)	периодически в облаке	да, но с задержкой — обновлённая политика раскатывается пакетом
Fleet-scale RL [1]	на роботе	versioned-snapshot data plane в облаке	почти-непрерывно, но асинхронно (каждый робот на своей версии до следующего снэпшота)

Работа *Learning While Deploying: Fleet-Scale Reinforcement Learning for Generalist Robot Policies* [1] описывает именно третий режим: edge-роботы копят наблюдения локально и заливают эпизоды в object storage через versioned-snapshot data plane; центральный координатор управляет снэпшотами, роботы периодически подтягивают свежую политику, а не синхронизируются мгновенно.

3 Конкретные примеры каждого подхода

Fully local

- **Gemini Robotics On-Device** [6] — компактная VLA-модель DeepMind, выполняющая составные манипуляционные задачи (расстегнуть сумку, сложить бельё) полностью офлайн, без обращения к облаку на инференсе.

- **Air-gapped suitcase robot на Jetson Orin NX** [7] — робот для GPS-denied сред без сетевого подключения вообще; локальный инференс Gemma-4 (E4B) с TensorRT, sub-200 мс отклик на обнаружение угроз, нулевой простой по сетевым причинам by design.
- **Промышленные манипуляторы с намеренно исключённым облаком** [8] — часть промышленных решений сознательно обходит облачную инфраструктуру целиком ради снижения кибер-риска; управление и (при наличии) дообучение остаются на предприятии.

Edge-cloud hybrid


- **Tesla Autopilot/FSD** [9] — инференс локально в автомобиле; в shadow mode модель параллельно человеку принимает решения, расхождения и «дизенгейджменты» отправляются в облако (пайплайн обрабатывает порядка 400 тыс. видеоклипов в секунду по флоту), переобучение — на суперкомпьютере Dojo, обновлённая модель раскатывается обратно во флот пакетом (firmware push), не поэпизодно.
- **Amazon Proteus/Sparrow + DeepFleet** [10] — локальное sensing и навигация на роботе (Proteus избегает препятствий и людей автономно), а координация флота (маршруты, зарядка, распределение задач) управляется облачной generative-AI моделью DeepFleet поверх множества устройств одновременно.

Fleet-scale RL / централизованный пул данных

- **Open X-Embodiment / RT-X** [11] — 34 исследовательские лаборатории слили 60 датасетов (1M+ траекторий, 22 типа роботов) в единый пул; RT-1-X/RT-2-X обучены централизованно на этом пуле — обучение происходит не «на роботе», а на агрегированном датасете флота целиком.
- **Learning While Deploying** [1] — сам архитектурный паттерн versioned-snapshot data plane (см. выше): эпизоды заливаются в object storage, обучение идёт центральным learner'ом, роботы периодически подтягивают свежий снэпшот политики.

Реальная рыночная оценка

Фактическая оценка одного аналитического агентства, а не самостоятельно собранная подборка примеров: Grand View Research в отчёте *Artificial Intelligence In Robotics Market* [12] даёт разбивку рынка ИИ в робототехнике по способу развёртывания за 2025 год: сегмент **on-premise** (вычисления на месте — устройство/локальная инфраструктура предприятия) занимает **73%** рыночной выручки, сегмент **cloud** (централизованные облачные AI-стеки, часто в модели robot-as-a-service) — оставшиеся **27%**; при этом cloud-сегмент прогнозируется как самый быстрорастущий по CAGR на 2026–2033.



■ On-premise (73% рыночной выручки) ■ Cloud (27%, самый быстрорастущий сегмент)

Важные оговорки, без которых эта цифра вводит в заблуждение:

- Это доля *рыночной выручки* (\$), а не доля *количества роботов* и не доля вычислительных архитектур — крупный on-premise-контракт (завод, оборонное предприятие) весит в этой цифре как угодно много, независимо от числа физических роботов.
- Таксономия отчёта **двухсторонняя** (on-premise / cloud), а не трёхсторонняя, как в разделе выше (fully local / edge-cloud hybrid / fleet-scale пул). «On-premise» в терминологии Grand View Research, вероятно, включает в себя и по-настоящему локальные системы, и часть edge-cloud hybrid (там, где обучение/агрегация происходит на серверах предприятия, а не в публичном облаке вендора) — то есть не эквивалентно нашей категории «fully local».
- Оценка одного агентства, без публичной методологии подсчёта (не census, а аналитическая модель) — для сопоставления стоило бы свести с 2–3 независимыми отчётами (Fortune Business Insights, Precedence Research), что не входит в объём этого ресёрча.

Тем не менее это единственная найденная в этом ресёрче цифра, которая хоть как-то количественно отвечает на вопрос «какая доля сейчас работает локально против облачно», и она согласуется с качественным выводом из примеров выше: локальное/on-premise исполнение пока доминирует по объёму развёртывания, а облачная/пул-модель — быстрее растёт, но с меньшей базы.

4 Почему inference не может быть полностью облачным

Обзор мультиагентных сетей на базе MLLM [2] приводит количественное объяснение: mobile edge computing (MEC), интегрированный в 5G, даёт задержку 5–10 мс против >50 мс у чисто облачного инференса. Для контура управления робота это критично — контроль требует локального (или edge-локального) исполнения политики. Измерительное исследование [3] на реальных манипуляционных workload напрямую подтверждает trade-off: offloading снимает вычислительные ограничения устройства, но добавочная сетевая задержка деградирует точность задачи. Работа *RAPID* [4] явно разбивает VLA-инференс между edge и cloud, достигая end-to-end задержки 222.9 мс, — прямое доказательство, что современные VLA-флоты используют *смешанную*, а не единую архитектуру инференса.

5 Крайний случай: обучение без взаимодействия

Robot Fleet Learning via Policy Merging (FLEET-MERGE) [5] описывает принципиально иной режим: роботы обучаются полностью автономно на своих данных, а политики сливаются *постфактум* — с учётом перестановочной инвариантности рекуррентных контроллеров. В этом режиме «мозг» не разделяется во время обучения вообще; агрегация происходит один раз, offline, над уже готовыми весами.

6 Следствие для модели угроз

Для privacy-анализа флота роботов важно зафиксировать одну конкретную архитектуру, а не рассуждать абстрактно: *inference* почти всегда локален (задержка контура управления не допускает облака), а *накопление опыта флота* вынесено в агрегатор. Атака на приватность целится именно в обновления, которые едут в облако (gray-box, агрегатор видит их) или в наблюдаемые выходы развёрнутой политики (black-box, внешний наблюдатель видит только действия) — но не в сам факт локального инференса, который приватен по построению архитектуры.

7 Тезаурус

Inference Применение уже обученной модели к новому наблюдению (в отличие от обучения — нет обновления весов).

Edge computing Вычисления на устройстве рядом с источником данных (сам робот или локальный узел рядом), а не в удалённом облачном датацентре.

MEC (Mobile Edge Computing) Разновидность edge computing, интегрированная в мобильные/телеком-сети (например, в 5G), дающая низкую задержку по сравнению с полностью облачной обработкой.

Edge-cloud hybrid Архитектура, где инференс идёт локально на устройстве, а обучение/переобучение — периодически в облаке с последующей раскаткой обновлённой модели обратно.

Fleet-scale RL Обучение с подкреплением, использующее опыт, накопленный целым флотом устройств, а не одним.

Versioned-snapshot data plane Инфраструктура, в которой роботы заливают эпизоды опыта в объектное хранилище, а координатор версионизирует снимки обучающих данных/политики, которые роботы периодически подтягивают.

Policy merging Слияние весов уже обученных независимо политик постфактум (offline), без взаимодействия роботов во время самого обучения.

Permutation invariance Свойство нейросети (особенно рекуррентной) давать эквивалентный результат при перестановке внутренних нейронов — учитывается при слиянии весов разных обученных экземпляров.

Gray-box / black-box (модель угроз) Gray-box — атакующий видит внутренние обновления модели (например, агрегатор). Black-box — атакующий видит только внешние выходы развёрнутой системы (например, действия робота).

On-premise Развёртывание вычислительной инфраструктуры на территории/ серверах самого предприятия-заказчика, а не в публичном облаке вендора; не то же самое, что «fully local» на уровне отдельного робота.

RaaS (Robot-as-a-Service) Бизнес-модель, при которой робота не покупают, а арендуют по подписке у вендора вместе с облачным AI-стеком и его обновлениями.

CAGR Compound Annual Growth Rate — среднегодовой темп роста рынка/сегмента за период, стандартная метрика в отчётах рыночных аналитиков.

Список литературы

- [1] *Learning While Deploying: Fleet-Scale Reinforcement Learning for Generalist Robot Policies*. arXiv:2605.00416, 2026.
- [2] *Advancing Multi-Robot Networks via MLLM-Driven Sensing, Communication, and Computation: A Comprehensive Survey*. arXiv:2604.00061, 2026.
- [3] *Offload or Overload: A Platform Measurement Study of Mobile Robotic Manipulation Workloads*. arXiv:2603.18284, 2026.
- [4] *RAPID: Redundancy-Aware and Compatibility-Optimal Edge-Cloud Partitioned Inference for Diverse VLA Models*. arXiv:2603.07949, 2026.
- [5] *Robot Fleet Learning via Policy Merging*. arXiv:2310.01362, 2023.
- [6] Google DeepMind. *Gemini Robotics On-Device*. deepmind.google, 2026.
- [7] *Offline Edge AI Robotics: Building a Fully Air-Gapped Suitcase Robot on Jetson Orin NX*. dasroot.net, 2026.
- [8] *Boosting Productivity with Industrial Robots: A Look at Remote Monitoring and Control Solutions*. automate.org, 2026.
- [9] *Computer Vision at Tesla for Self-Driving Cars*; Tesla FSD shadow mode and Dojo training pipeline (public engineering disclosures), 2026.
- [10] *How Amazon deploys robots in its operations facilities: Proteus, Sparrow, DeepFleet*. aboutamazon.com, 2025–2026.
- [11] *Open X-Embodiment: Robotic Learning Datasets and RT-X Models*. arXiv:2310.08864, 2023.
- [12] Grand View Research. *Artificial Intelligence In Robotics Market Report, 2026–2033* — deployment segmentation (on-premise 73%, cloud 27%, 2025). grandviewresearch.com, 2025.